
Analyse et classification de la santé fœtale

Hani Zaki
20176047
hani.zaki@umontreal.ca

Yannick Boily
20189162
yannick.boily@umontreal.ca

David Marinier
20117967
david.marinier@umontreal.ca

Table des matières

1	Introduction	2
2	Objectifs	2
3	Description des données analysées	2
3.1	Features & Classes	3
3.2	Analyse générale	3
4	Méthodologie d'analyse	5
4.1	Machine à vecteurs de support (SVM)	5
4.2	Arbre de décision et forêt aléatoire	5
4.3	Bayes Naïf	6
4.4	Réduction de dimensionnalité	7
5	Résultats	7
5.1	SVM linéaire	7
5.2	SVM avec noyau gaussien	7
5.3	Arbre de décision	8
5.4	Forêt aléatoire	9
5.5	Bayes Naïf	10
5.6	Modele Combinatoire	11
5.7	Représentation graphique des prédictions avec réduction de dimensionnalité	13
5.7.1	SVM avec MDS	13
5.7.2	Bayes Naïf avec Isomap	13
6	Discussion des résultats	13
7	Conclusion	14
8	Contribution des membres	15
9	Reference	15

1 Introduction

La surveillance fœtale est essentielle dans le suivi de la grossesse, permettant d'identifier les risques potentiels pour le fœtus. Le dataset disponible sur Kaggle comprend des données issues de cardiocotogrammes, utilisées pour évaluer l'état de santé du fœtus. Ce projet vise à exploiter des techniques de la science des données pour développer un système capable de classer la santé fœtale en trois catégories : normale, suspecte, et pathologique.

Pour réaliser ce projet nous utiliserons des modèles de classification tels que les machines à vecteurs de support (SVM), les arbres de décision, les forêts aléatoires et le Naïve Bayes, tout en comparant leurs efficacités et précisions. Nous utiliserons également des méthodes de réduction de dimensionnalité tel que PCA, MDS et Isomap.

2 Objectifs

Le but de ce projet est de concevoir et de comparer plusieurs modèles de la science des données afin de déterminer le plus adapté pour la classification de la santé fœtale. Les objectifs spécifiques sont :

- Développer et entraîner les modèles SVM, arbres de décision, forêts aléatoires, et Naïve Bayes pour classer les états de santé fœtale.
- Comparer l'efficacité et la précision de ces modèles sur les données.
- Appliquer des techniques de réduction de dimensionnalité tel que MDS et PCA et comparer la performance des modèles.

De plus, nous présenterons une visualisation 2D de la prédiction de certains modèles utilisés.

3 Description des données analysées

Les données pour ce projet proviennent d'examens cardiotocogrammes, soit des examens médicaux qui analysent les bruits du coeur des bébés et les contractions lors de la grossesse. Ces examens ont par la suite été évalués par 3 spécialistes obstétriciens qui ont classés les données en 3 catégories (normal, suspect, pathologique). Les données sont donc médicales et ont été obtenues lors de l'évaluation de patients par des professionnels de la santé. La base de donnée devrait donc être fiable, considérant l'importance lors de ce type d'examen pour la survie du bébé.

Le dataset contient des données tabulaire continues, il y a des features qui sont des statistiques sommaires comme la médiane et le maximum de l'histogramme, mais il y a également des features plus spécialisés tel que le mouvement fetal et le nombre de décélérations. Pour ce qui est de la dernière colonne du jeu de données, elle n'est pas continue. Elle représente plutôt l'étiquette attribuée par les experts lors de leurs évaluations. Le jeu de données comprend 2126 entrées qui ont chacune 21 features et une variable de classe.

3.1 Features & Classes

Les features sont tous des données continues. On les présente ici :

- `baseline_value` : Fréquence cardiaque de base du fœtus (battements par minute).
- `accelerations` : Nombre d'accélération par seconde.
- `fetal_movement` : Nombre de mouvements fœtaux par seconde.
- `uterine_contractions` : Nombre de contractions utérines par seconde.
- `light_decelerations` : Nombre de décélérations légères par seconde.
- `severe_decelerations` : Nombre de décélérations sévères par seconde.
- `prolongued_decelerations` : Nombre de décélérations prolongées par seconde.
- `abnormal_short_term_variability` : Pourcentage de temps avec une variabilité à court terme anormale.
- `mean_value_of_short_term_variability` : Valeur moyenne de la variabilité à court terme.
- `percentage_of_time_with_abnormal_long_term_variability` : Pourcentage de temps avec une variabilité à long terme anormale.
- `mean_value_of_long_term_variability` : Valeur moyenne de la variabilité à long terme.
- `histogram_width` : Largeur de l'histogramme de la fréquence cardiaque fœtale.
- `histogram_min` : Fréquence minimale de l'histogramme de la fréquence cardiaque fœtale.
- `histogram_max` : Fréquence maximale de l'histogramme de la fréquence cardiaque fœtale.
- `histogram_number_of_peaks` : Nombre de pics dans l'histogramme.
- `histogram_number_of_zeroes` : Nombre de zéros dans l'histogramme.
- `histogram_mode` : Mode de l'histogramme.
- `histogram_mean` : Moyenne des valeurs de l'histogramme.
- `histogram_median` : Médiane des valeurs de l'histogramme.
- `histogram_variance` : Variance des valeurs de l'histogramme.
- `histogram_tendency` : Tendance observée dans l'histogramme.

Pour les classes, on a :

- `fetal_health` : 1 (Normal), 2 (Suspect) et 3 (Pathologique)

3.2 Analyse générale

Nous notons tout d'abord qu'il n'y a aucune données manquantes. On commence par regarder les boxplots pour chaque colonne(Figure 1).

Pour plusieurs features, il y a une concentration des données autour d'un nombre et quelques données "extrêmes". Par exemple, on peut constater cet effet, entre autres, pour les variables `fetal_movement` et `prolongued_decelerations`. On voit aussi qu'il y a possiblement un déséquilibre des classes. Le dernier boxplot, qui est celui des classes, nous montre que la majorité est dans la classe 1. Voyons cela plus en détails :

En effet, on a 1655 cas classifiés dans la classe 1, c'est-à-dire des cas normaux. Ce genre de déséquilibre peut causer des problèmes, et sera adressé au besoin selon les algorithmes. Regardons maintenant la matrice de corrélation à la figure 3 (on omet le nom des features pour ne pas encombrer) :




FIGURE 1 – Boxplots des données

```
fetal_health
1.0    1655
2.0     295
3.0     176
Name: count, dtype: int64
```

FIGURE 2 – Compte des classes



FIGURE 3 – Matrice de corrélation des features

On voit de forte corrélation entre plusieurs features. Ces features sont les mesures histogram. Ce n'est pas surprenant, puisque c'est des mesures prise d'un même histogramme (supposément). Pour le reste, on ne voit pas de corrélation particulièrement forte. Nous prenons la décision de garder toutes les features, même si certains sont fortement corrélés.

4 Méthodologie d'analyse

Considérant que notre projet est un projet de classification de données étiquetées, lors de notre méthode d'analyse nous avons choisi 3 méthodes de classification qui ont été vu en classe soit les SVM (Support Vecteur Machine), les arbres de décision et la classification bayésienne. Nous avons choisi des méthodes supervisées, car les données sont étiquetées.

Nous avons également opté pour ne pas faire de regroupement (Partionnel, Densité, Hiérarchique) avec des algorithmes qui sont des algorithmes non-supervisés, tels que DBScan ou encore K-Means, car il n'était pas nécessaire pour le projet de trouver de nouveaux clusters ou de trouver des structures intrinsèques à nos données en raison du fait que les étiquettes sont fournies avec le jeu de données. Les étiquettes fournies indiquent quelles données fait partie de quel cluster.

Nous avons aussi décidé d'expérimenter avec des algorithmes de réduction de dimensionnalité pour réduire le nombre de dimensions ainsi que nous permettre de visualiser la classification des données dans un graphique. Nos données ayant 22 dimensions, nous avons aussi l'intention de tester voir si des concepts tels que la malédiction de la dimensionnalité allaient affecter la performance de nos algorithmes de classification en raison de la rareté des données en hautes dimensions. Pour cela nous avons décidé d'utiliser PCA, MDS et Isomap et de les appliquer en combinaison avec divers algorithmes de classification.

4.1 Machine à vecteurs de support (SVM)

Une machine à vecteurs de support est fondamentalement un algorithme de classification binaire et multiclassés, rendant ainsi son utilisation pertinente pour des problèmes d'apprentissage supervisés comme celui-ci. Pour la classification multiclassée, la méthode va construire un hyperplan par classe. De plus, la méthode permet de spécifier un paramètre C , permettant ainsi d'avoir une marge "molle", c'est-à-dire une marge qui permet des points mal classifiés (en d'autres mots, des points de l'autre côté de la marge). La formule d'un tel SVM est comme suit :

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

tel que :

$$\begin{aligned} y_i(\mathbf{w} \cdot \mathbf{x}_i + b) &\geq 1 - \xi_i, \quad \forall i = 1, \dots, n \\ \xi_i &\geq 0, \quad \forall i = 1, \dots, n \end{aligned}$$

où

$$y_i \in \{1, 2, 3\} \forall i \quad \text{Puisqu'on a 3 classes}$$

En classification multiclassée, il existe deux méthodes pour construire les hyperplans : *One vs Rest* (OvR) et *One vs One* (OvO). On utilisera la méthode OvR, qui consiste à construire un hyperplan pour chaque classe, de tel sorte qu'il maximise la marge entre cette classe et toutes les autres classes regroupées.

Pour ce qui est du SVM non linéaire, nous utiliserons la méthode du noyau. Plus précisément, nous utiliserons un noyau gaussien. Ce noyau est particulièrement utile pour capturer des relations complexe entre les caractéristiques des données. La formule d'un SVM avec noyau gaussien est similaire à celle d'en haut, sauf qu'on remplace $\mathbf{x}_i$ par $\phi(\mathbf{x}_i)$, qui est une fonction qui map les données dans un autre espace. Le noyau gaussien est définie ainsi :

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$$

Et

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$$

où la dernière équation vient du théorème de Mercer.

4.2 Arbre de décision et forêt aléatoire

L'arbre de décision a été une des méthodes choisies pour le projet, car c'est une méthode simple, mais efficace de faire de la classification. Les algorithmes d'arbres consistent généralement en quelques étapes qui sont :

- Initialisation du dataset comme racine
- Trouver le meilleur attribut pour séparer l'arbre
- Créer une branche et un enfant pour chaque subset
- Continuer l'algorithme de façon récursive pour chaque nœud enfant et subset associé
- L'algorithme arrête lorsque toutes les données dans les nodes ont le même label, il n'y a plus de label à séparer ou le node est vide.

Pour notre arbre l'algorithme choisi a été un algorithme CART, ce qui implique que notre arbre avait seulement des divisions binaires. L'algorithme utilise l'index de Gini pour faire ses separations qui se calcul de cette façon :

$$Gini(t) = 1 - \sum_C (p(c|t))^2$$

Nous avons également utilisé les forêts aléatoires. Une forêt aléatoire est une méthode qui combine des arbres de décision et agrège leurs résultats. Les forêts aléatoires sont reconnus pour offrir plusieurs avantages tels qu'une bonne robustesse face aux données aberrantes, une bonne précision lors des prédictions et réduit le risque de surapprentissage.

Les étapes pour faire l'algorithme d'une random forest sont les suivantes :

- Créer des sous-ensembles en tirant de façon aléatoire des échantillons avec remplacement dans l'ensemble des données. (Bootstrapping)
- Construire les arbres de décision pour chaque échantillon
- Agréger les prédictions de chaque échantillon
- Évaluation du modèle et Optimisation des hyperparamètre

4.3 Bayes Naïf

Le dernier modèle de classification que nous utiliserons est le modèle bayésien naïf. Celui-ci est basé sur une approche probabiliste qui fait appel au théorème de Bayes pour classer les données. Le théorème de Bayes stipule que la probabilité conditionnelle de la classe C en sachant l'observation x peut être calculé de la façon suivante :

$$P(C|x) = \frac{P(x|C) P(C)}{P(x)} \quad (1)$$

Où :

- $P(C|x)$ est la probabilité à postériori de C sachant x ;
- $P(x|C)$ est la vraisemblance de x en sachant C ;
- $P(C)$ est la probabilité à priori de C ;
- $P(x)$ est la distribution d'observation de x .

Cette méthode regarde donc chaque attribut de nos données et trouve la probabilité qu'une donnée soit dans une certaine classe C à partir des probabilités conditionnelles de ses attributs. La classification Bayésienne est dite "naïve", car celle-ci assume que les différents attributs de notre base de données sont indépendants les uns des autres, c'est-à-dire que :

$$P(x_1|C, x_2, \dots, x_n) = P(x_1|C)$$

Où x_n représente l'attribut n . Avec cette hypothèse la formule (1) peut être transformé :

$$P(C|x_1, x_2, \dots, x_n) = \frac{P(C) \cdot \prod_{i=1}^n P(x_i|C)}{P(x_1, x_2, \dots, x_n)} \quad (2)$$

Chaque donnée est ensuite classé selon : $\arg \max_C P(C|x_1, x_2, \dots, x_n)$.

Lorsque nous estimons les probabilités conditionnelles, il peut arriver que certaines valeurs de x_n n'apparaissent pas dans notre ensemble d'entraînement pour une classe donnée C ce qui entraîne une probabilité conditionnelle de zéro. Pour éviter cela nous pouvons utiliser la correction de Laplace qui ajoute une valeur α tel que :

$$\Pr[x_j = a|C = C_i] \approx \frac{\#\{x : x_j = a \wedge x \in C_i\} + \alpha}{\#\{x : x \in C_i\} + k}$$

Où :

- $\Pr[x_j = a | C = C_i]$ est la probabilité conditionnelle de l'attribut $x_j = a$ étant donné que la classe est C_i .
- $\#\{x : x_j = a \wedge x \in C_i\}$ est le nombre d'occurrences où l'attribut $x_j = a$ et où x appartient à la classe C_i .
- $\#\{x : x \in C_i\}$ est le nombre total d'occurrences dans la classe C_i .
- k est le nombre total de valeurs possibles de l'attribut x_j .

4.4 Réduction de dimensionnalité

Pour la réduction de dimensionnalité nous avons prévu utiliser 3 méthodes PCA, MDS et Isomap.

PCA : l'analyse en composantes principales (PCA) est une approche standard de réduction de la dimensionnalité. PCA cherche à capturer la variance maximale dans les données. Son algorithme est le suivant : 1-Centrage des données 2- Calcul de la matrice de covariance. 3- SVD ou Eigendecomposition 4- Projection des vecteurs et valeurs propres.

MDS : MDS offre une alternative à PCA basée sur les relations ou les distances dans les données. Son algorithme classique est le suivant : 1- Formuler les distances carrés 2- Construire une matrice de gram en faisant un double centrage. 3- SVD ou Eigendecomposition. 4- Attribuer les coordonnées en les basant sur les vecteurs propres et valeurs propres

Isomap : Isomap regarde la distance géodésique (distance la plus courte sur une courbe) entre les données pour identifier leur relation. Voici les étapes principales de l'algorithme Isomap : 1- On commence par construire un graphe de voisinage pour chaque point composé de ses k-NN (k nearest neighbors) en termes de distance euclidienne. 2- On calcule les distances géodésiques pour chaque paires de points dans le graphe de voisinage. 3- On peut ensuite appliquer l'algorithme MDS sur les distances calculé au point 2. pour créer une représentation visuelle.

5 Résultats

Pour l'analyse des résultats nous avons calculé la précision des classificateurs, fait une matrice de confusion et utilisé un rapport de classification. Tous les résultats ont été calculés avec un ratio de données Training/Test de 75/25 avec un random state de 42 pour pouvoir reproduire les résultats. Nous avons également décidé de faire des graphes pour voir l'évolution de la précision en fonction du ratio des données de Training/Test. Il faut également considérer que nous avons un problème où les classes sont déséquilibrées, ce qui implique qu'un modèle prédisant toujours 1 aurait environ 78% de précision il faut donc que nos résultats soient supérieurs à cette valeur pour que nos résultats prédisent correctement.

5.1 SVM linéaire

Pour le SVM linéaire à marge dure nous avons obtenu une précision de 89,47%. Tandis que le svm linéaire à marge molle nous a donné une précision de 90,79%. Il est facilement explicable que le modèle à marge molle est plus précis, car celui à marge solide cherche à faire une séparation parfaite des données, ce qui ne considère pas le bruit ou les données aberrantes dans le dataset. Celui à marge molle a une tolérance à ces données ce qui augmente sa précision, car dans des applications réelles ou il y a souvent des données qui seraient du mauvais côté de la séparation.

5.2 SVM avec noyau gaussien

Un SVM à noyau gaussien (C=10) nous a donné une précision de 93,61% et était plus performant que le svm linéaire. De plus les données dans le graphe d'accuracy sont très stables d'un point à l'autre ce qui indique que le modèle est robuste.

```


Classification Report:
      precision    recall  f1-score   support

     1:   0.95   0.94   0.95    413
     2:   0.68   0.71   0.69     82
     3:   0.75   0.61   0.78     37

 accuracy: 0.80
 macro avg: 0.80   0.82   0.81    532
 weighted avg: 0.90   0.69   0.90    532

Model accuracy: 89.47%

```



(a) SVM linéaire à marge dure ($C=1$)

```


Classification Report:
      precision    recall  f1-score   support

     1:   0.94   0.96   0.95    413
     2:   0.75   0.68   0.71     82
     3:   0.65   0.78   0.72     37

 accuracy: 0.85
 macro avg: 0.85   0.81   0.83    532
 weighted avg: 0.90   0.91   0.91    532

Model accuracy: 90.79%

```



(b) SVM linéaire à marge molle ($C=0.021$)

FIGURE 4

```


Classification Report:
      precision    recall  f1-score   support

     1:   0.97   0.96   0.96    413
     2:   0.89   0.83   0.81     82
     3:   0.69   0.89   0.78     37


 accuracy: 0.89
 macro avg: 0.89   0.89   0.89    532
 weighted avg: 0.94   0.94   0.94    532

Model accuracy: 93.61%

```



(a) SVM avec noyau gaussien ($C=10$)




(b) Accuracy SVM avec noyau gaussien selon test size ($C=10$)

FIGURE 5

5.3 Arbre de décision


Pour les arbres de décision nous avons obtenu une précision de 93,8%. Les arbres de décision sur des données sur lesquelles PCA a été appliqué sont moins précis dans leur prédiction dans nos tests pour 10 composants. Nous avons ensuite fait un graphe pour représenter la variance qui est gardée dans les données en fonction du nombre de composantes choisies pour PCA et on peut voir (dans la figure 7b) qu'à partir de 6 composantes, le ratio de variance conservé commence à se stabiliser près de 1 donc 10 composant devraient être suffisant pour garder une bonne variance dans les données.

Decision Tree				
Model accuracy: 93.80%				
	precision	recall	f1-score	support
1.0	0.97	0.95	0.96	413
2.0	0.80	0.85	0.83	82
3.0	0.92	0.95	0.93	37
accuracy			0.94	532
macro avg	0.90	0.92	0.91	532
weighted avg	0.94	0.94	0.94	532




(a) Résultats Decision Tree

Decision Tree PCA				
Model accuracy: 87.03%				
	precision	recall	f1-score	support
1.0	0.94	0.91	0.93	413
2.0	0.63	0.65	0.64	82
3.0	0.69	0.92	0.79	37
accuracy			0.87	532
macro avg	0.76	0.83	0.79	532
weighted avg	0.88	0.87	0.87	532




(b) Résultats Decision Tree avec réduction PCA

FIGURE 6



(a) Accuracy selon le test size Decision Tree




(b) Ratio variance gardée dans les données selon le nombre de composants


FIGURE 7

5.4 Forêt aléatoire

Le modèle de Random Forest nous a permis de prédire à 95,49% la classe de chaque donnée de test. Nous pouvons aussi voir que le modèle qui utilise les données réduites avec PCA pour 10 composants est beaucoup moins précis que le modèle sur les données non-réduite.



(a) Résultats Random Forest



(b) Résultats Random Forest avec réduction PCA

FIGURE 8




FIGURE 9 – Graph de l'accuracy en fonction du test-size

5.5 Bayes Naïf

Le modèle de Bayes Naïf nous a permis de prédire à 83,27% la classe de chaque donnée de test. Nous pouvons aussi voir que le modèle qui utilise les données réduites avec Isomap est plus précis que le modèle sur les données non-réduite et que l'addition d'un facteur α est critique pour notre modèle.




FIGURE 10


5.6 Modele Combinatoire

Le modèle combinatoire consiste en une combinaison de trois modèle distinct pour faire les prediction il contient le SVM avec noyau Gaussien($C=10$), un decision tree et une random forest. Ensuite, il y a un système de "vote" pour les 3 modèles qui font chacun leur prediction et l'agrégation de ces 3 votes est ensuite utilisé pour déterminer le label.

Nous avons testé un modèle au poids fixe où chaque modèle avait 1 vote sur 3 et un modèle soft dans lequel les probabilités de la classe prédite sont considérées. Ce type de modèle a bien fonctionné pour les 2 types de poids en offrant une précision de 95,86% tel qu'on peut le voir dans la figure 11. La figure 12 nous permet de voir la précision de la classification selon le test size et on peut voir que la précision du modèle augmente selon le training size jusqu'à environ 22% avant de réduire un peu de façon semblable à ce qu'elle fait pour le modèle de décision tree (Figure 7a). Ce qui est logique considérant que le modèle de decision tree est un des 3 modèles combinés. On peut également voir qu'avec un sample de training trop petit la précision chute et qu'avec un sample de test trop petit il y a beaucoup de variation, car une fluctuation du nombre de prédictions mauvaise avec cette grosseur de sample affecte grandement l'accuracy.

Voting Classifier Hard Weighted
Model accuracy: 95.86%


	precision	recall	f1-score	support
1.0	0.97	0.99	0.98	413
2.0	0.91	0.84	0.87	82
3.0	0.97	0.92	0.94	37
accuracy	0.95	0.92	0.96	532
macro avg	0.96	0.96	0.96	532
weighted avg	0.96	0.96	0.96	532



(a) Résultats Modèle combinatoire avec système de vote soft avec poids fixe


Voting Classifier Soft Weighted
Model accuracy: 95.40%

	precision	recall	f1-score	support
1.0	0.97	0.98	0.97	413
2.0	0.88	0.84	0.86	82
3.0	0.97	0.95	0.96	37
accuracy	0.94	0.92	0.95	532
macro avg	0.95	0.95	0.95	532
weighted avg	0.95	0.95	0.95	532




(b) Résultats Modèle combinatoire avec système de vote avec poids soft

FIGURE 11



(a) Précision du Modèle combinatoire avec système de vote avec poids fixe selon le test size




(b) Précision du Modèle combinatoire avec système de vote avec poids soft selon le test size


FIGURE 12

5.7 Représentation graphique des prédictions avec réduction de dimensionnalité

5.7.1 SVM avec MDS



5.7.2 Bayes Naïf avec Isomap



6 Discussion des résultats

En regardant nos résultats, il est évident que certains des modèles performant mieux que d'autres. Parmi tous nos modèles, le modèle Bayes naïf est le moins performant. Cela peut être causé par plusieurs facteurs différents. Premièrement, ce modèle repose sur l'indépendance conditionnelle des variables. Cela signifie que si certaines caractéristiques sont fortement corrélées entre elles, le classifieur bayésien naïf peut ne pas être en mesure de capturer ces relations et de bien généraliser.

Deuxièmement, il est plus sensible aux attributs continus, car il utilise une distribution de loi gaussienne pour approximer la distribution des données continues, et si celle-ci n'est pas une bonne approximation, cela peut entraîner de mauvaises performances. Finalement, étant donné que le classifieur bayésien naïf suppose une certaine distribution de probabilité pour chaque caractéristique, les valeurs extrêmes ou aberrantes peuvent fausser cette distribution et entraîner des prédictions erronées.

Le modèle de décision tree et de random forest ont tous les deux très bien fonctionné avec des précisions de 95,49%(RDF) et 93,8% (decision tree). Nous avons également remarqué que les randoms forests étaient plus efficaces avec nos données que les arbres individuels. Cela s'explique parce que les forêts aléatoires sont plus robustes et réduisent la variance. Lors de la recherche de solutions optimales pour les random forest la fonction d'optimisation de paramètres a trouvé plusieurs solutions qui utilisaient des centaines d'arbres avec une profondeur de plus de 20, la grande diversité dans les arbres a donc permis de bien modéliser les relations.

Le modèle SVM avec noyau gaussien démontre aussi de bons résultats avec des niveaux de prédiction de 93,61% . Cela démontre qu'il est mieux adapté pour classifier notre base de données qu'un modèle de prédiction linéaire. Il est capable de mieux capturer les relations non linéaires entre les attributs et les classes et est plus robuste contre le bruit.

Le modèle combinatoire a été le meilleur modèle avec une précision de 95,86%. Cependant ce modèle est celui qui demande le plus de computations, car il utilise 3 autres modèles qui ont très bien fonctionné pour faire sa classification. Il n'est donc pas vraiment surprenant qu'un modèle basé sur 3 modèles avec plus de 92% de précision ait réussi à faire une bonne classification.

Nos tests pour MDS et PCA n'ont pas donné d'augmentation de précision dans les SVM, les arbres et random forest au contraire les résultats obtenus avec ceux-ci étaient généralement quelques pourcentage moins précis ce qui s'explique par la perte d'informations causée par ces deux techniques, car les modèles réels sont souvent trop complexes pour être facilement exprimés en plus basse dimension avec seulement quelques paramètres.

7 Conclusion

Dans cette étude, le modèle combiné et le modèle de random forest ont montré qu'ils sont très efficaces et appropriés à la classification d'examen Cardiotocogramme malgré les contraintes causées par base de données relativement petite sur la quantité d'entraînement possible des modèles. Cependant, le modèle n'est pas parfait et l'appliquer dans l'évaluation des CTG n'est pas possible considérant qu'il y a des cas pathologiques et suspects qui sont considérés comme normaux. Il resterait donc possible de l'améliorer ou de trouver des nouvelles solutions encore plus précises et performantes.

Des voies qui pourraient être intéressantes d'explorer pourraient être l'utilisation de machine learning que ce soit en combinaison avec des modèles de classification tels que les randoms forests ou de façon individuelle. L'expérimentation avec une nouvelle et plus grande base de données pourrait également aider les projets futurs. Ce type de développement pourrait même être utile un jour pour offrir des modèles robustes qui peuvent être appliqués dans le domaine de la santé pour peut-être sauver des vies.

8 Contribution des membres

Voici la contribution de chaque membre :

- Yannick Boily :
 - Analyse des données.
 - Implémentation des modèles Forêt aléatoire, PCA , arbre de décision et modèle combinatoire.
 - Écriture du rapport
- David Marinier :
 - Implémentation des modèles Bayes naïf et représentation graphique avec Isomap.
 - Écriture du rapport
- Hani Zaki :
 - Analyse des données.
 - Implémentation des modèles SVM et représentation graphique avec MDS.
 - Écriture du rapport

9 Reference

Base de données : Ayres de Campos et al. (2000) SisPorto 2.0 A Program for Automated Analysis of Cardiotocograms. J Matern Fetal Med 5:311-318

Lien téléchargement base de données : <https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>